

张少聪 - AI 应用开发/Java 后端开发

个人网站 | 18727967108 | 18727967108@163.com | 硕士研究生 | 江苏南京



教育背景

2024.09-至今	南京邮电大学 (双一流)	电子信息 (硕士)
2020.09-2024.06	成都理工大学 (双一流)	电子信息工程 (本科)

科研经历

- 国家自然科学基金项目 (92367302): 基于新型体系架构全要素按需协同互联的工业互联网集成系统及验证, 负责后端核心场景业务模块开发, 负责完成项目文档撰写与结题验收。
- 中国发明专利: 张少聪, 张晖, 一种传播环境反演认知的 6G 指纹定位模型智能重构方法, 2026108534550, 2026-06-12。

专业技能

- AI 工程化范式: 熟练 Claude Code/Codex AI 辅助开发工具, 掌握 AI 智能体规范体系及知识库搭建。
- AI 应用开发: 掌握 LangChain/LangChain4j、RAG、Memory、Function Calling/MCP、流式输出、RAGFlow。
- 后端开发: 掌握 Java、Spring Boot、MyBatis-Plus、Spring Cloud Alibaba, 熟悉 Python。
- 数据存储与中间件: 掌握 MySQL、Redis、MongoDB、OpenSearch、RabbitMQ、Kafka、XXL-JOB。
- 工程化与协作工具: 熟练使用 Docker、Git、Linux 进行部署与版本管理; 具备工程化的全栈交付能力。

实习经历

亚信安全科技股份有限公司 — 通用软件开发工程师 (2026.06—2026.07)

参与企业级 SOC 安全运营中心 (旗下各类安全产品告警与安全事件的统一运维平台) 全栈开发。

- 后端开发:** 用户管理认证系统 (CRUD + OTP + 多角色权限模型)、工作台事件 API (列表/统计/筛选/排序 + OpenSearch 查询兼容与优化)、AI 批量研判系统 (@Async 线程池编排+内存状态机+事务后派发+逐事件错误隔离+启动恢复钩子)、LLM 调用链路优化 (CloseableHttpClient 连接池复用、事务解耦、AI/人工研判数据分离、从原始告警 payload 构建提示词上下文)、安全运营事件通告推送外部系统企业微信群集成。
- 前端开发:** 双层导航架构重构 (TopNav 一级 + Sidebar 二级动态渲染), 基于 TanStack Query v5 + shadcn/ui 的工作台处置全链路 (列表/详情/研判/处置/通知编辑), MSW v2 Mock 驱动开发 + Vitest 单元测试, OpenSearch string eventId 架构适配, 安全事件告警详情抽屉多轮迭代。
- 数据链路:** 参与多源告警接入与处理链路开发: 多源告警接入→Kafka→范式化+聚合+安全事件规则引擎匹配→OpenSearch 存储→AI 研判闭环→工作台处置, 实现优化关键页面加载耗时降低约 35%。
- Agent 工程化建设:** 为 Claude Code /Codex 搭建 AI 辅助开发规范体系, 落地三层 AGENTS.md 分层加载和.agents/ 知识库 (20+开发规范文件), 设计 ROUTING.md 任务路由表实现按需加载语言、领域、流程、安全、契约规范, 建立了 Spec→Plan→Code、Review→Fixes 的 SDD (Superpowers Driven Development) 闭环开发流程。

项目经历

基于智能体协作的智慧医疗服务平台 (2026.02—2026.04)

- AI 引擎构建：基于 LangChain4j 框架集成阿里百炼平台 Qwen 大模型，通过 AIService 代理实现模型交互。深度整合 RAG 技术，利用 Pinecone 向量数据库为医院、科室等非结构化文档构建专业知识库，增强回答的专业性与准确性。
- 智能体核心功能：通过 Function Calling 机制，自定义开发预约挂号、取消预约等业务工具，使大模型能根据对话意图自动化调用后端微服务，实现从自然语言交互到业务操作的全链路闭环。设计多层提示词模板，赋予智能客服分导诊、挂号助手等专业身份。
- 记忆与流式交互：采用 TokenWindowChatMemory 实现多轮对话记忆，利用 MongoDB 持久化会话历史，解决上下文遗忘问题。集成 WebFlux 实现大模型的逐 token 流式输出，将首字响应时间缩短至 200ms 以内，显著提升交互体验。
- 微服务业务支撑：基于 Spring Cloud Alibaba 构建微服务集群，涵盖用户、医院、订单等模块。使用 MySQL 存储核心业务数据，引入 MongoDB 满足排班数据的高并发读写。通过 RabbitMQ 对订单状态进行异步更新与短信通知，确保高并发下的数据最终一致性。

基于 RAGFlow 的多源知识库智能问答平台 (2025.10—2025.12)

- 核心架构：基于 RAGFlow 构建多知识库空间，通过 API 封装实现知识库创建、文档解析、向量化及聊天助手管理。后端采用 LangChain 搭建 RAG 管道，集成阿里 Qwen 大模型，为前端提供统一智能问答接口。
- 智能意图路由与工具调用：应用 LangChain 的 Function Calling/MCP 技术，将“列出助手”、“指定助手回答”、“自动匹配回答”三种模式封装为标准工具。LLM 能根据用户查询，自动调用工具并精准分发至不同知识库，实现多助手无缝协作。
- 记忆管理与查询增强：利用 MongoDB 持久化存储 ConversationBufferMemory，实现多轮对话记忆。独立设计查询增强模块，结合 LLM 将对话历史中的代词等还原为具体实体，有效解决多助手切换及长对话场景下的上下文遗忘问题。
- 异步流式交互：采用异步生成器接口统一封装整个处理流程。后端实现全链路异步处理，具备良好的并发支撑能力。前端利用数据流实时渲染，显著提升多轮深度问答的交互体验。

AI 驱动的智能组卷与阅卷系统 (2025.06—2025.08)

- AI 能力深度集成：通过 WebClient + Moonshot HTTP API 集成 Kimi 大模型，设计精细化的提示词工程驱动 AI 实现智能出题、自动组卷及简答题的语义级自动评分全自动化生成。针对 AI 交互的不稳定性，设计了带 3 次重试容错机制的调用方案，针对 API 速率限制和结果格式异常进行自动重试，确保服务的健壮性。
- 高性能排行榜与缓存：针对考试排行榜场景，通过自定义 SQL (JOIN + TIMESTAMPDIFF) 将原先的 N+1 次查询优化为单次关联查询，将排行榜接口平均响应时间从 2200ms 降至 180ms，提升超过 10 倍。利用 Redis ZSet 数据结构记录题目热度，实现热门题目排行榜，并设计了缓存预热与优雅降级策略。
- 存储与数据批量处理：集成 MinIO 提供统一的文件存储服务，在核心资源删除时增加前置校验，防止数据孤岛。基于 Apache POI 设计“预览→校验→导入”两阶段流程，实现 Excel 数据批量导入导出，通过 @Transactional 保障多表写入的事务一致性。