

张少聪- AI 应用开发/Java 后端开发



18727967108 | 18727967108@163.com | 硕士研究生(在读) | 江苏南京 | 随时到岗

教育背景

2024.09-至今	南京邮电大学 (双一流)	电子信息 (硕士)
2020.09-2024.06	成都理工大学 (双一流)	电子信息工程 (本科)

科研经历

- 国家自然科学基金项目 (92367302): 基于新型体系架构全要素按需协同互联的工业互联网集成系统及验证, 参与后端核心业务模块开发, 协助完成项目文档撰写与结题验收。
- 中国发明专利: 张少聪, 张晖, 一种传播环境反演认知的 6G 指纹定位模型智能重构方法, 2026108534550, 2026-06-12。

专业技能

- AI 应用开发: 精通 LangChain/LangChain4j 框架, 熟练掌握 RAG、Memory、Function Calling/MCP、流式输出等核心技术; 具备 RAGFlow、Coze/Dify 等平台的实战经验, 可独立完成 RAG 检索链路搭建、智能体开发与复杂工作流编排。深度掌握提示词工程, 能针对不同业务场景设计高效 Prompt。
- 后端开发: 精通 Java 核心, 熟练掌握 Spring Boot、MyBatis-Plus 及 Spring Cloud Alibaba (Nacos、Sentinel、OpenFeign、Gateway), 具备构建高可用分布式系统的设计与开发能力; 深入理解并发编程及 JVM 原理。同时熟练掌握 Python 基础, 具备良好编程思维与代码规范。
- 数据存储与管理: 熟练掌握 MySQL, 熟练掌握索引优化、锁机制、事务隔离级别及性能调优。熟练掌握 Redis 核心数据结构、持久化策略, 能利用 Redisson 等工具解决分布式锁、缓存异常 (穿透/击穿/雪崩) 等复杂问题。熟练应用 MongoDB 文档型数据库与 Elasticsearch 搜索引擎。
- 中间件与消息系统: 熟练使用 Docker 部署各类中间件。深入掌握 RabbitMQ 消息队列, 能利用延迟消息等特性解决复杂业务问题。掌握 Canal 数据同步、XXL-JOB 分布式任务调度及 CompletableFuture 异步编排。
- 开发工具: 熟练使用 Claude Code、Codex 等 AI 编程工具; 熟悉 Git 版本控制; 具备 Linux 操作基础。

实习经历

• 亚信安全科技股份有限公司 — 通用软件开发工程师 (2025.03—2025.09)

- 企业级 SOC 平台研发: 参与企业级安全运营中心 SOC 平台的前端及部分 Web 后端开发, 负责告警可视化看板、事件详情、事件溯源、自动化响应工单、客户管理等核心模块, 实现安全告警的集中展示、查询分析与运营处置。
- 告警数据链路建设: 参与多源安全告警接入与处理链路开发, 支持 DS 通过 Syslog 接入, TrustOne、TDA、AI XDR 通过 Kafka 接入; 配合 LogStash、KafkaStream 完成告警清洗、客户信息补全、范式化、白名单过滤与聚合处理, 并将告警数据写入 openSearch 和 MySQL。
- AI 智能研判功能: 开发安全事件 AI 研判相关功能, 对接外部研判服务, 实现安全事件读取、研判调用、结果回写和状态展示, 辅助安全分析师完成告警初筛与事件分类, 降低重复人工研判成本。
- 性能优化与稳定性提升: 优化安全告警、聚合告警、安全事件和工作台工单的列表查询与详情展示, 使平台关键页面加载耗时降低约 35%, 告警从生成到展示的平均延迟缩短至 1 秒以内, 支撑安全运营团队 7×24 小时威胁监控与快速响应。

● 基于智能体协作的智慧医疗服务平台 — AI 应用开发 (2026.02—2026.04)

- AI 引擎构建：基于 LangChain4j 框架集成阿里百炼平台 Qwen 大模型，通过 AIService 代理实现模型交互。深度整合 RAG 技术，利用 Pinecone 向量数据库为医院、科室等非结构化文档构建专业知识库，增强回答的专业性与准确性。
- 智能体核心功能：通过 Function Calling 机制，自定义开发预约挂号、取消预约等业务工具，使大模型能根据对话意图自动化调用后端微服务，实现从自然语言交互到业务操作的全链路闭环。设计多层提示词模板，赋予智能客服分导诊、挂号助手等专业身份。
- 记忆与流式交互：采用 TokenWindowChatMemory 实现多轮对话记忆，利用 MongoDB 持久化会话历史，解决上下文遗忘问题。集成 WebFlux 实现大模型的逐 token 流式输出，将首字响应时间缩短至 200ms 以内，显著提升交互体验。
- 微服务业务支撑：基于 Spring Cloud Alibaba 构建微服务集群，涵盖用户、医院、订单等模块。使用 MySQL 存储核心业务数据，引入 MongoDB 满足排班数据的高并发读写。通过 RabbitMQ 对订单状态进行异步更新与短信通知，确保高并发下的数据最终一致性。

● 基于 RAGFlow 的多源知识库智能问答平台 — AI 应用开发 (2025.10—2025.12)

- 核心架构：基于 RAGFlow 构建多知识库空间，通过 API 封装实现知识库创建、文档解析、向量化及聊天助手管理。后端采用 LangChain 搭建 RAG 管道，集成阿里 Qwen 大模型，为前端提供统一智能问答接口。
- 智能意图路由与工具调用：应用 LangChain 的 Function Calling/MCP 技术，将“列出助手”、“指定助手回答”、“自动匹配回答”三种模式封装为标准工具。LLM 能根据用户查询，自动调用工具并精准分发至不同知识库，实现多助手无缝协作。
- 记忆管理与查询增强：利用 MongoDB 持久化存储 ConversationBufferMemory，实现多轮对话记忆。独立设计查询增强模块，结合 LLM 将对话历史中的代词等还原为具体实体，有效解决多助手切换及长对话场景下的上下文遗忘问题。
- 异步流式交互：采用异步生成器接口统一封装整个处理流程。后端实现全链路异步处理，设计的异步处理方案，通过 JMeter 本地压测，能稳定支持 100+ 用户并发提问并实时返回结果。前端利用数据流实时渲染，显著提升多轮深度问答的交互体验。

● 高并发有声读物服务平台 — 后端开发 (2025.08—2025.10)

- 核心业务与框架：基于 Spring Cloud Alibaba 构建微服务，独立完成专辑、声音、订单、支付等核心模块。集成微信支付 V3 API，通过 AOP 切面与自定义注解实现登录态校验，保障接口安全。利用 RabbitMQ 延迟消息插件实现未支付订单自动取消，并引入策略模式优化多种支付场景的业务逻辑。
- 高性能检索与缓存：基于 Elasticsearch 构建专辑检索服务，支持分词搜索、高亮、多维度排序及关键字自动补全。利用 Redis + Redisson 分布式锁 + 布隆过滤器构建多层缓存架构，经本地对比测试，该架构将核心接口 QPS 从 500 提升至 8000，有效解决了高并发场景下的缓存击穿与穿透问题。通过 Canal 监听 MySQL binlog，实现缓存数据的准实时同步，保障数据一致性。
- 数据一致性与异步处理：使用 RabbitMQ 解耦专辑上/下架、播放量统计等业务，保障数据最终一致性。利用 CompletableFuture + 自定义线程池实现专辑详情等复杂数据查询的异步并行编排，提升接口响应速度。集成 XXL-JOB 实现排行榜定时更新、VIP 状态批量处理等分布式定时任务。
- 高性能排行榜与缓存：针对排行榜场景，通过自定义 SQL (JOIN + TIMESTAMPDIFF) 将原先的 N+1 次查询优化为单次关联查询，该优化将排行榜接口的平均响应时间从 2200ms 降至 180ms，提升了超过 10 倍。利用 Redis ZSet 数据结构记录专辑热度，实现热门专辑排行榜，并设计了缓存预热与优雅降级策略，确保服务的高可用。